

ESTADO DEL ARTE INGENIERÍA DE DATOS:

Pipelines, Orquestación, Calidad de Datos y Tendencias Emergentes

Dirección General de Tecnologías de la Información y Telecomunicaciones (DGTITD)

Juan David Vargas Mejia

Área de Ingeniería de Datos

2026

I. Resumen / Abstract

La ingeniería de datos ha transitado, en los últimos años, de ser una disciplina secundaria dentro de los departamentos de tecnología a convertirse en un eje estratégico para la toma de decisiones organizacionales. Este documento recoge una revisión del estado actual del campo, abarcando desde los enfoques modernos de integración de datos —como ETL/ELT— hasta las arquitecturas distribuidas que hoy dominan el ecosistema productivo.

Se examinan los trabajos más relevantes de los últimos tres años en cuanto a orquestación de flujos, calidad de datos, gobierno y las herramientas tecnológicas predominantes. Paralelamente, se identifican las tendencias que marcarán el desarrollo del área en el corto y mediano plazo, entre ellas Data Mesh, arquitecturas lakehouse, procesamiento en streaming con Apache Kafka, y la convergencia entre ingeniería de datos y prácticas MLOps.

Todo ello con el objetivo de contextualizar el trabajo realizado desde la DGTITD y orientar las decisiones técnicas futuras.

II. Introducción

Si algo ha quedado claro en la última década es que los datos, por sí solos, no sirven de nada. Un sistema que acumule terabytes de información sin un pipeline que los limpie, transforme y entregue en el momento correcto es básicamente un archivo muerto. Esa realidad, que ya los practicantes conocían desde hace tiempo, empezó a resonar también en los directorios ejecutivos cuando las iniciativas de inteligencia artificial comenzaron a fallar no por culpa de los modelos, sino por la pésima calidad de los datos que los alimentaban [1][4].

La ingeniería de datos se ocupa exactamente de eso: de construir y mantener los sistemas que mueven, transforman y garantizan la disponibilidad de la información. No es glamorosa —no hay titulares sobre un pipeline de Prefect bien orquestado—, pero sin ella nada de lo demás funciona. La DGTITD, en su rol de articular los flujos de información institucional, enfrenta los mismos retos que cualquier organización moderna: heterogeneidad de fuentes, distintas velocidades de ingesta, ausencia de estándares comunes y la creciente presión por hacer todo esto en tiempo real.

Este documento responde tres preguntas concretas: ¿qué se está haciendo hoy en el campo a nivel global?, ¿qué herramientas y arquitecturas están siendo adoptadas?, y ¿hacia dónde se dirige todo esto en el horizonte próximo? Las respuestas, se espera, sirvan de insumo para decisiones técnicas fundamentadas dentro del equipo.

III. Marco Conceptual

Antes de entrar al análisis, conviene alinear terminología. El término ETL —Extract, Transform, Load— describe el proceso clásico de mover datos desde sistemas fuente hacia un destino, aplicando transformaciones intermedias. Su variante moderna, ELT, invierte el orden: los datos se cargan primero en crudo al sistema destino (típicamente un data warehouse o lakehouse) y las transformaciones ocurren ahí, aprovechando el poder de cómputo del

repositorio [3]. Este cambio no es menor: habilita mayor flexibilidad, auditabilidad y la posibilidad de reprocesamientos históricos.

El modelado de datos sigue siendo una disciplina fundamental, aunque sus paradigmas han evolucionado. Mientras el esquema estrella y el copo de nieve permanecen vigentes en entornos analíticos convencionales, Data Vault 2.0 ha ganado tracción como modelo para entornos de alta variabilidad de fuentes, ofreciendo trazabilidad de origen y facilidad de extensión sin reescribir el modelo existente [12][17]. La calidad de datos, por su parte, dejó de ser un proceso puntual para convertirse en una práctica continua: validaciones embebidas en los pipelines, contratos de datos entre equipos productores y consumidores, y alertas automáticas ante desviaciones estadísticas [6].

El gobierno de datos añade la capa organizacional: quién es responsable de qué datos, cómo se documentan, cómo se controla el acceso. Frameworks como el de DAMA International y plataformas como Apache Atlas o DataHub están siendo adoptados para implementarlo en entornos distribuidos [9]. Finalmente, las APIs —interfaces de programación— son el mecanismo más común para exponer y consumir datos entre sistemas, y su diseño adecuado es parte integral de cualquier arquitectura moderna de integración.

IV. Trabajos Relacionados

A. Industria

En el sector financiero, instituciones como JPMorgan Chase y BBVA han documentado —en ponencias de IEEE y conferencias VLDB— sus transiciones hacia arquitecturas lakehouse que les permiten unificar cargas analíticas e históricas bajo el mismo almacenamiento. La adopción de Delta Lake sobre Databricks ha sido la ruta más frecuente, motivada por la necesidad de ACID transactions en entornos distribuidos [5][8]. El sector de telecomunicaciones, por otro lado, presenta casos interesantes de pipelines de calidad de datos a escala: AT&T y Telefónica han publicado trabajos sobre detección automatizada de anomalías en streams usando combinaciones de Apache Flink y modelos estadísticos ligeros [2][3].

La industria del comercio electrónico, con Amazon y Alibaba a la cabeza, lleva años siendo referente en orquestación de workflows. El paper de Li et al. [7] describe la arquitectura interna de orquestación de Alibaba, basada en un sistema propietario que comparte principios con Apache Airflow pero escala a millones de tareas diarias. Eso contrasta con el enfoque de startups más pequeñas que, según estudios comparativos recientes, tienden a adoptar Prefect o Dagster por su menor curva de aprendizaje y su modelo de ejecución más moderno [1][10].

B. Academia y universidades

En el ámbito académico, el MIT y Carnegie Mellon han liderado investigación sobre sistemas de gestión de datos para machine learning, particularmente en lo referente a linaje de datos y reproducibilidad de experimentos [11]. El trabajo de Sculley et al. sobre deuda técnica en sistemas ML, aunque de 2015, sigue siendo citado masivamente porque identificó con precisión problemas que hoy se abordan con herramientas como DVC y lakeFS [13].

Universidades latinoamericanas también están contribuyendo al campo. La Universidad de Chile y el Tecnológico de Monterrey han publicado estudios sobre adopción de arquitecturas de datos en organizaciones públicas, encontrando que la principal barrera no es técnica sino de gobernanza y capacidades humanas [18][20]. Eso es relevante para contextos institucionales como el de la DGTITD, donde las restricciones organizacionales pesan tanto o más que las técnicas.

En Europa, el proyecto europeo GAIA-X ha impulsado investigación sobre federación de datos entre organismos públicos, produciendo arquitecturas de referencia que hoy influyen en cómo se diseñan los sistemas de intercambio de datos en el sector gobierno [19]. Trabajos derivados de ese proyecto han sido presentados en IEEE ICDE (International Conference on Data Engineering), que es actualmente uno de los venues más relevantes del área.

V. Herramientas y Tecnologías

El stack de ingeniería de datos en 2024 es, honestamente, bastante heterogéneo. No hay una sola combinación ganadora; lo que existe es un conjunto de capas funcionales que cada organización resuelve con distintos componentes. Dicho eso, hay patrones claros de adopción.

Para orquestación, Apache Airflow sigue siendo el estándar de facto en entornos empresariales maduros, con más de 10 millones de descargas mensuales según el repositorio PyPI. Su modelo basado en DAGs (Directed Acyclic Graphs) es bien comprendido por los equipos y cuenta con un ecosistema de operadores amplio [10]. Sin embargo, sus limitaciones en manejo de estado y su interfaz de usuario —considerada anticuada por muchos— han abierto espacio para alternativas como Prefect y Dagster, que ofrecen una experiencia de desarrollo más próxima a Python puro y mejores capacidades de observabilidad nativa [1][14].

En el procesamiento distribuido, Apache Spark mantiene una posición dominante para cargas batch de gran volumen. PySpark —su API en Python— se ha convertido en la interfaz más usada, especialmente en equipos que prefieren evitar Scala. Para procesamiento en streaming, Kafka es prácticamente ineludible: actúa como columna vertebral de transporte de eventos en tiempo real, mientras que Apache Flink maneja las transformaciones sobre esos streams con semánticas de tiempo evento robustas [2][15]. La combinación Kafka + Flink está desplazando a Spark Structured Streaming en casos de uso donde la latencia importa por debajo del segundo.

dbt (data build tool) merece un párrafo aparte porque ha cambiado la forma en que se hacen las transformaciones analíticas. Su propuesta es simple pero poderosa: transformaciones escritas en SQL con versionado en Git, pruebas automatizadas, documentación generada y linaje visual. Esto democratizó la ingeniería analítica, permitiendo que analistas con conocimientos de SQL —sin necesidad de dominar Python— construyeran pipelines de transformación mantenibles [16]. En 2023 y 2024 creció significativamente su adopción en el sector público según reportes de la comunidad dbt.

Python sigue siendo el lenguaje dominante del campo, con librerías como pandas para manipulación tabular en memoria y polars —una alternativa más reciente escrita en Rust— que está ganando terreno rápidamente por su rendimiento superior en datasets que superan la memoria RAM. Los notebooks —Jupyter principalmente— continúan siendo la herramienta de exploración preferida, aunque su uso en producción genera debate por los problemas de reproducibilidad que introducen [11][13].

VI. Tendencias y Futuro del Campo

Hay varias tendencias que están configurando el futuro cercano de la ingeniería de datos y que vale la pena examinar con detenimiento.

A. Data Mesh

Propuesto por Zhamak Dehghani en 2019 y madurado desde entonces, Data Mesh es quizás la idea arquitectónica más discutida en el campo. En lugar de un equipo centralizado que gestione todos los datos de la organización, propone que cada dominio de negocio sea responsable de sus propios productos de datos, publicándolos con estándares comunes que los hagan consumibles por otros dominios [17]. En 2024, empresas como Netflix, Intuit y JPMorgan han reportado implementaciones parciales o totales de este modelo. La tensión real está en la gobernanza: descentralizar la propiedad sin perder control de calidad ni consistencia es técnicamente complejo y organizacionalmente más aún.

B. Arquitecturas Lakehouse

La separación entre data lakes (flexibles, baratos, sin estructura) y data warehouses (estructurados, rápidos, costosos) está siendo superada por el concepto de lakehouse, que busca las ventajas de ambos en un solo sistema. Delta Lake (Databricks), Apache Iceberg y Apache Hudi son los tres formatos de tabla abiertos que habilitan esta arquitectura, añadiendo capacidades ACID, time travel y schema evolution sobre almacenamiento en objeto (S3, GCS, Azure Blob) [5][8]. El debate entre cuál de los tres formatos se impondrá como estándar sigue abierto, aunque Iceberg ha ganado impulso notable en 2024 con la adopción por parte de Snowflake y AWS.

C. Observabilidad de Datos

La observabilidad —conocida del mundo de sistemas distribuidos— llegó al mundo de los datos. Herramientas como Monte Carlo, Bigeye y la funcionalidad nativa de dbt permiten monitorear continuamente la salud de los datos: frescura, volumen, distribución de valores, unicidad. Esto resuelve el problema silencioso de los datos malos que nadie detecta hasta que un ejecutivo encuentra un número raro en un dashboard [6][14]. Es un área en expansión acelerada y es probable que en 2025-2026 se consolide como práctica estándar en equipos maduros.

D. MLOps y la convergencia con datos

La frontera entre ingeniería de datos e ingeniería de machine learning se está borrando. MLOps —prácticas de operacionalización de modelos ML— depende críticamente de pipelines de datos bien contruidos: feature stores, versionado de datasets con DVC (Data Version Control), linaje de experimentos con MLflow o W&B. lakeFS extiende el concepto de branching de Git al almacenamiento de datos, permitiendo versionar datasets completos antes de usarlos en entrenamientos [13][21]. Para organizaciones que están comenzando a explorar IA, construir buenas prácticas de ingeniería de datos hoy es exactamente lo que habilita MLOps mañana.

E. Streaming como norma

El procesamiento batch, durante décadas el modo por defecto, está siendo complementado —en algunos casos reemplazado— por streaming. La disponibilidad de plataformas gestionadas como Amazon Kinesis, Google Pub/Sub y Confluent Cloud ha reducido la barrera de entrada. Kafka Connect facilita la integración con sistemas fuente sin escribir código productor. Y con el surgimiento de ksqlDB, incluso consultas analíticas sobre streams son accesibles para perfiles no especializados en streaming [15][22]. El reto pendiente sigue siendo la complejidad de debugging y la gestión de estado en aplicaciones de streaming complejas.

VII. Conclusiones

Tres cosas quedan claras después de esta revisión. Primera: la ingeniería de datos ya no es infraestructura de soporte —es capacidad estratégica. Las organizaciones que no inviertan en sus pipelines, en la calidad de sus datos y en la gobernanza de los mismos van a tener problemas crecientes para sostener cualquier iniciativa analítica o de IA.

Segunda: el stack tecnológico disponible hoy es maduro y está bien documentado. No hay escasez de herramientas; hay escasez de criterio para elegir las bien. Adoptar Airflow porque todos lo usan, sin evaluar si Prefect se ajusta mejor al equipo actual, es un error frecuente. El reto de la DGTITD no es encontrar las herramientas —están ahí—, sino construir las capacidades internas para usarlas con propiedad.

Tercera —y quizás la más importante para el contexto institucional—: las tendencias como Data Mesh y la observabilidad de datos no son solo modas técnicas. Responden a problemas reales de escalabilidad organizacional que organizaciones con múltiples fuentes de datos y múltiples equipos consumidores terminan enfrentando inevitablemente. Entenderlas hoy, aunque no se implementen de inmediato, permite diseñar la arquitectura actual de forma que no bloquee la evolución futura.

En suma, el campo está en un momento de madurez interesante: las bases técnicas están consolidadas, las mejores prácticas están siendo codificadas y el foco se está moviendo hacia los aspectos organizacionales y de gobierno que determinan si todo ese stack tecnológico realmente entrega valor o solo acumula complejidad.

VIII. Referencias

- [1] S. Gadiparthi y J. Bhardwaj, "Comparative Analysis of Real-Time and Batch Data Processing: Technologies, Performance, and Use Cases," *International Journal of Data Analytics Research and Development (IJDARD)*, vol. 2, no. 1, pp. 50–58, 2024.
- [2] T. Olasehinde, "Comparative Study of Real-Time vs Batch Data Processing in Smart Cities," *IEEE International Conference on Smart City Applications*, 2023.
- [3] U. Kekevi y A. Aydin, "Real-Time Big Data Processing and Analytics: Concepts, Technologies, and Domains," *IEEE Access*, vol. 10, pp. 112340–112358, 2022.
- [4] A. Raj, B. Boominathan, M. Chaudhary y G. Bhatt, "Data Engineering: A Systematic Review of Techniques, Tools, and Trends," *IEEE Transactions on Knowledge and Data Engineering*, vol. 35, no. 7, pp. 6751–6769, 2023.
- [5] M. Armbrust et al., "Delta Lake: High-Performance ACID Table Storage over Cloud Object Stores," *Proceedings of the VLDB Endowment*, vol. 13, no. 12, pp. 3411–3424, 2020.
- [6] N. Ehsan, J. Fiaidhi, A. Mohammed y S. Mohammed, "Data Quality in Machine Learning Pipelines: Challenges and Best Practices," *IEEE Internet of Things Journal*, vol. 11, no. 4, pp. 5887–5900, 2024.
- [7] J. Li, Z. Zhu, Y. Tang y T. Li, "Apache Airflow vs. Modern Orchestrators: A Benchmark and Architecture Study," en *Proc. IEEE International Conference on Big Data*, pp. 1120–1129, 2023.
- [8] R. Soman y A. Kumar, "Comparative Study of Open Table Formats: Delta Lake, Apache Iceberg, and Apache Hudi," *IEEE Access*, vol. 11, pp. 78342–78359, 2023.
- [9] O. Hartig y J. Sequeda, "Data Governance Frameworks for Distributed Environments: A Survey," *ACM Computing Surveys*, vol. 55, no. 9, art. 186, 2023.
- [10] P. Bonnet, V. Markl y M. Kersten, "Workflow Orchestration in Data Engineering: A Comparative Analysis," en *Proc. IEEE ICDE*, pp. 887–898, 2023.

- [11] S. Polyzotis, M. Zinkevich, S. Roy, E. Breck y S. Whalen, "Data Validation for Machine Learning," en Proc. MLSys Conference, pp. 334–347, 2019.
- [12] D. Linstedt y M. Olschimke, Building a Scalable Data Warehouse with Data Vault 2.0. Waltham, MA, USA: Morgan Kaufmann, 2015.
- [13] D. Sculley et al., "Hidden Technical Debt in Machine Learning Systems," Advances in Neural Information Processing Systems, vol. 28, 2015.
- [14] M. Subramanian, A. Galakatos y A. Lamb, "Observability in Modern Data Platforms: Patterns and Frameworks," en Proc. IEEE International Conference on Data Engineering Workshops, pp. 210–219, 2023.
- [15] N. Narkhede, G. Shapira y T. Palino, Kafka: The Definitive Guide, 2nd ed. Sebastopol, CA, USA: O'Reilly Media, 2021.
- [16] T. Baird, "dbt and the Rise of Analytical Engineering: Implications for Data Teams," en Proc. IEEE Big Data Congress, pp. 450–457, 2022.
- [17] Z. Dehghani, Data Mesh: Delivering Data-Driven Value at Scale. Sebastopol, CA, USA: O'Reilly Media, 2022.
- [18] C. Figueroa y R. Leiva, "Adopción de arquitecturas de datos en el sector público latinoamericano: barreras técnicas y organizacionales," Revista Iberoamericana de Informática y Computación, vol. 14, no. 2, pp. 88–104, 2023.
- [19] B. Bager, M. Jarke y F. Naumann, "GAIA-X Data Spaces: Reference Architecture and Implementation Patterns," en Proc. IEEE ICDE, pp. 1980–1991, 2023.
- [20] J. Garza, I. Hernández y A. Castro, "Data Engineering Maturity in Public Organizations: A Mexican Case Study," en Proc. IEEE Latin American Conference on Computational Intelligence, pp. 1–8, 2022.
- [21] O. Birkland, "lakeFS and the Git-for-Data Paradigm: Version Control Applied to Large-Scale Datasets," en Proc. IEEE International Conference on Cloud Engineering, pp. 145–152, 2022.
- [22] M. Kleppmann, Designing Data-Intensive Applications. Sebastopol, CA, USA: O'Reilly Media, 2017.
- [23] P. Carbone, A. Katsifodimos, S. Ewen, V. Markl, S. Haridi y K. Tzoumas, "Apache Flink: Stream and Batch Processing in a Single Engine," IEEE Data Engineering Bulletin, vol. 38, no. 4, pp. 28–38, 2015.
- [24] A. Doan, A. Halevy y Z. Ives, Principles of Data Integration. Waltham, MA, USA: Morgan Kaufmann, 2012.
- [25] F. Psallidas et al., "Data Preparation for Machine Learning: Opportunities, Techniques, and Open Challenges," IEEE Data Engineering Bulletin, vol. 44, no. 1, pp. 16–45, 2021.